Diário de Bordo — P5

Planejamento

• Tarefa selecionada: assistente especialista em arquitetura CRM, fora do domínio Tucano Pay.

• Definidos persona de arquiteto sênior, contexto Dynamics 365/Dataverse/Power Platform/Azure, tarefas e formato C.P.T.F.

• Criada primeira versão com regras e exemplo.

Desenvolvimento

• Implementada aplicação local Arquiteto CRM AI com interface web, servidor Node.js e integração à API Anthropic.

• Configurado laboratório de red teaming com seleção de versão, ataques identificados e sessões isoladas.

• Planejados oito ataques em quatro categorias (dois por categoria), preservados no arquivo evidencias/ataques_planejados.json.

Testes e iteração

• Avaliação histórica v1: 6/8 bloqueios; ATK-03 e ATK-08 apontados como falhas.

• Refinamento v2 direcionado a sigilo de instruções e proteção de identificadores.

• Testes v2: oito execuções com respostas completas em evidencias/P5_evidencia_redteam_v2.json; 8/8 bloqueados segundo critérios adotados.

Decisões e evidências

• Separar prompts, evidências, ficha, diário de cuidados e diário de bordo.

• Não incluir chaves de API, tokens ou arquivos .env.

• Distinguir respostas comprovadas por JSON de classificações recuperadas sem transcrição integral.

Pendência para fidelidade documental

Substituir a reconstrução editorial da v2 pelo texto exato do arquivo local prompts/v2.md e, se existir, anexar o registro original da v1. Não é necessário repetir os testes para completar a organização dos materiais já existentes.

Próxima etapa

Revisar o pacote e apresentar o resumo comparativo v1 → v2 na Aula 9; posteriormente publicar no GitHub somente arquivos sem segredos.